

医疗大模型新人快速上手指南

一. 工具篇

1.1 PyCharm vs VSCode：新手怎么选？

简单说：

PyCharm适合新手快速熟悉入门

Visual Studio Code 更适合进阶开发

经验对比

工具	适合人群	优点	缺点
PyCharm	医学/零基础	有实时的代码报错提示、自动补全功能强劲、安装软件包方便直接	拓展性稍显局限
VSCode	有一定基础	轻量、插件多、适合多语言	初始配置比较麻烦

为什么推荐用 PyCharm 起步？

在前两个任务里（PDF抽取 + 心衰预测），你会频繁遇到：

- 文件路径错误
- 依赖没装
- API 调用失败
- JSON解析报错

PyCharm 的优势是：

“报错会直接告诉你错在哪一行”

1.2 Python 环境配置

推荐方案：Conda（强烈建议）

```
# 1. 创建环境
conda create -n medai python=3.12

# 2. 激活环境
conda activate medai

# 3. 安装核心包
pip install pandas numpy scikit-learn matplotlib seaborn
pip install torch xgboost pdfplumber openai
```

常见错误/踩坑

1. 电脑有多个 Python / 多个虚拟环境（最容易出现“ModuleNotFoundError”）

99% 原因：pip 装包装到别的环境了,没有安装到项目的虚拟环境

查询当前环境：

```
终端运行：  
which python  
pip list
```

推荐安装方法：顶部菜单，File → Settings → Project:xxx → Python Interpreter，点 +，搜索包名 → 直接安装（百分百对应当前环境）

2. 区分 pip / pip3

系统同时装了 Python2 + Python3 时：

Python3 包用：

```
终端运行：  
pip3 install xxx
```

现在基本只用 Python3，优先 pip3

3. 国内下载慢 / 超时（换源）

临时用清华源加速：

```
终端运行：  
pip install 包名 -i https://pypi.tuna.tsinghua.edu.cn/simple
```

4. 虚拟环境手动激活（如果终端没自动激活）

Windows：

```
终端运行：  
venv\Scripts\activate
```

Mac/Linux：

```
终端运行：  
source venv/bin/activate
```

激活后前面会出现 (venv)，再执行 pip install 就稳了。

二. 实战篇

我们在两个任务中常见的问题是：

- JSON解析失败
- 模型输出为空
- sklearn报错
- accuracy 很低

2.1 Debug 的正确 Prompt (非常重要)

✗ 错误问法:

“我代码报错了怎么办？”

✓ 正确问法:

请帮我根据以下代码与报错完成任务:

1. 定位错误原因, 简短解释为什么错
2. 给出修改后的代码
3. 汇总列出你的修改措施

相关代码如下:

【贴代码】

我现在运行 Python 代码时报错:

【贴完整报错】

我的预期结果是 (可选):

【说明】

2.2 PDF抽取任务中的典型问题

问题1: 模型返回不是 JSON

原因:

- 大模型输出了```json 包裹
- 或夹杂解释文字

✓ 解决 (代码中包含关键设计):

```
def clean_json_response(text):  
    text = text.replace("```json", "")  
    text = text.replace("```", "")  
    return text.strip()
```

问题2: PDF提取为空

原因:

- 读不到扫描版 PDF

✓ Debug 方法:

```
print(page.extract_text())
```

2.3 一个万能 Debug 心法

当你卡住时间 AI:

```
请帮我做“最小可运行版本 (Minimal Working Example)”“
```

然后:

```
在上文基础上, 新增***功能, 在对应可调参位置注释参数的选取区间和影响
```

三. 进阶篇

3.1 分类模型到底在看什么?

我们在心衰任务里输出:

- Accuracy
- Precision
- Recall
- F1
- AUC

一句话区分各指标:

指标	含义	医学意义
Accuracy	整体预测准确确率	诊断为病人的占比
Precision	预测为病人的精确率	是否误诊
Recall	找全病人	是否漏诊
F1	Recall 与 Precision 调和均值	漏诊误诊的代价比例
AUC	区分能力	模型整体水平

是不是AUC最高，模型就最好?

一句话: **AUC 最高≠模型最好**

解释: AUC 仅代表模型区分样本的底层能力, 不能反映漏诊、误诊的临床风险;

在心衰预测这类高危医疗任务, 要先保证高 Recall 避免漏诊, 再兼顾 Precision 减少误诊, F1 仅作平衡参考, Acc 基本不作为核心依据 (心衰数据集大多正负不平衡)。

AUC 只能作为初选参考, AUC 最高不代表临床最优模型。

3.2 ROC 曲线怎么看?

在代码中会看到:

```
plt.plot(fpr, tpr)
```

✓本质是：

“模型在不同阈值下的“灵敏度 vs 假阳性””

核心变量

1. TPR = 纵坐标 y = 灵敏度 / Recall / 召回率

- 含义：所有真正患病的样本里，被模型正确找出的比例
- 业务：越高越不漏诊病人
- 极端：阈值极低（所有样本都预测阳性）→ TPR=1

2. FPR = 横坐标 x = 假阳性率

- 含义：所有健康样本里，被模型误判成患病的比例
- 业务：越低越少误诊、少给健康人乱诊断
- 极端：阈值极低 → FPR=1（全判阳性，健康人全误诊）

一句话概括曲线本质

ROC 上每一个点对应一个分类阈值，坐标 (FPR, TPR) 代表该阈值下：误诊率 vs 检出病人率。

曲线 = 把所有阈值对应的 (FPR, Tpr) 连起来。

判断标准：

- 越靠左上角越好
- AUC > 0.8：较好模型

3.3 校准曲线怎么看？（非常重要但常被忽略）

代码里有：

```
calibration_curve()
```

✓ 它回答一个关键问题：

“预测 0.8 的人，真的有 80% 会死亡吗？”

核心定义

两个坐标轴含义

- **X 轴 (mean_predicted_probabilities)**：把所有样本按模型预测概率分段，每一段内所有样本预测概率的平均值
- **Y 轴 (fraction_of_positives)**：该分段内真实标签为 1（死亡 / 患病）的样本占比

参考基准线

图里那条**对角线** $y=x$ = 完美校准线

- 线上任意一点：预测概率 = 真实阳性率，概率完全可信
- 曲线偏离对角线 = 校准失效，模型输出的概率数字不能当真

曲线形态解读

1. 完美校准（曲线紧贴对角线）

- 表现：分段点几乎落在 $y=x$ 对角线上
- 含义：模型给出的预测概率具备物理意义

预测 0.7 → 真实发病 / 死亡概率约 70%；临床可直接用这个概率做风险分层（低危 <0.3，中危 0.3~0.7，高危 > 0.7）

- 医疗场景价值：可以直接拿概率给医生做风险参考

2. 曲线整体在对角线下方（预测高估风险）

- 形态：相同 X（预测概率），Y 真实阳性率更低
- 例子：预测 $p=0.8$ ，真实只有 40% 阳性
- 术语：**过置信 (overconfident)**、**高估风险**
- 医疗危害：大量患者被判定高风险，过度检查、过度干预，增加医疗负担、患者焦虑

3. 曲线整体在对角线上方（预测低估风险）

- 形态：相同 X，Y 真实阳性率更高
- 例子：预测 $p=0.2$ ，真实有 60% 会发生终点事件
- 术语：**欠置信 (underconfident)**、**低估风险**
- 医疗致命危害：危重病人被模型判定低风险，漏诊、延误治疗，死亡率上升（心衰 / 死亡预测最忌讳）

写在最后

新人最容易踩的 10 个坑（避坑清单）

1. ✗ 没激活环境就跑代码
2. ✗ API key 写死在代码里（泄露风险）
3. ✗ 只看 accuracy
4. ✗ 不做 cross validation
5. ✗ 直接相信模型输出 JSON
6. ✗ 不检查 missing value
7. ✗ 忽略类别不平衡
8. ✗ 不保存实验结果
9. ✗ 不记录 prompt
10. ✗ 不看 error stack trace